


描述性统计分析在 RNA-seq 数据中的应用

方法梳理与 GSE193613 count 数据案例

用规模、中心、离散、分布和样本结构先建立数据背景，再进入差异分析解释。

描述性统计分析在 RNA-seq 数据中的应用



案例数据：规模、分组与测序深度

count 矩阵包含 21,975 个基因和 6 个样本

saline 对照组: S1、S2、S3


GlcN/E 给药组: G1、G2、G3

全零基因 4,718；至少一个样本检出基因 17,257

library size 范围: 28.89M 至 35.51M

这些数值作为数据检查结果原样保留；raw count 不直接用于样本间强比较。



Library size / total counts by sample



集中趋势与离散程度：均值被长尾拉高

全矩阵 raw count 均值 1,445.77，中位数 196
样本均值范围 1,314.61–1,615.95
样本中位数范围 181–214
均值 / 中位数比值约 7.05 至 7.62
min = 0，max = 916,158，极差 916,158
众数 0 出现 37,331 次，占全部观测值 28.31%
样本 SD 范围 6,821.84–9,843.64；CV 范围 4.52–6.68

均值不是错，但在 RNA-seq raw count 中必须和中位数、IQR、SD/CV 一起读。



分布与样本结构: **log** 转换让主体更清楚

raw count : P99 = 16,957.22 , max = 916,158 , 偏度 43.49




$\log_2(\text{count} + 1)$: P99 = 14.05 , max = 19.81 , 偏度 -0.179

raw count 超额峰度 3,321.49 ; $\log_2$ 后超额峰度 -1.48

edgeR TMM 标准化后 logCPM : Pearson r 范围 0.9839–0.9884

PCA : PC1 解释 25.7% , PC2 解释 21.6% , 合计 47.3%

PCA 用于结构概览和离群观察, 不作为显著差异证据。




结论：描述性统计提供质量背景

无缺失值；零计数比例接近； **library size** 处于同一数量级
raw count 右偏长尾明显，因此中位数、IQR、log 转换和
logCPM 更稳妥

IQR 排序最高基因: mt-Co1, IQR = 237,564.75

21,975 个转录本经筛选后 13,293 个进入分析; DESeq2 得到 321 个差异转录本

saline 高表达 147 个, GlcN/E 高表达 174 个



GSEA : IL-17 signaling pathway NES = -1.688 , P = 1.484e-03 ;
ECM-receptor interaction NES = 1.606 , P = 5.401e-05 ; Dilated
cardiomyopathy NES = 2.055 , P = 3.925e-06

